OS概念与Linux内核源代码分析之1

May 17, 2012

本课程Linux内核版本

- linux kernel: 2.6.24
- 为什么？older? newer?
- 下载地址: www.kernel.org

Linux内核整体架构

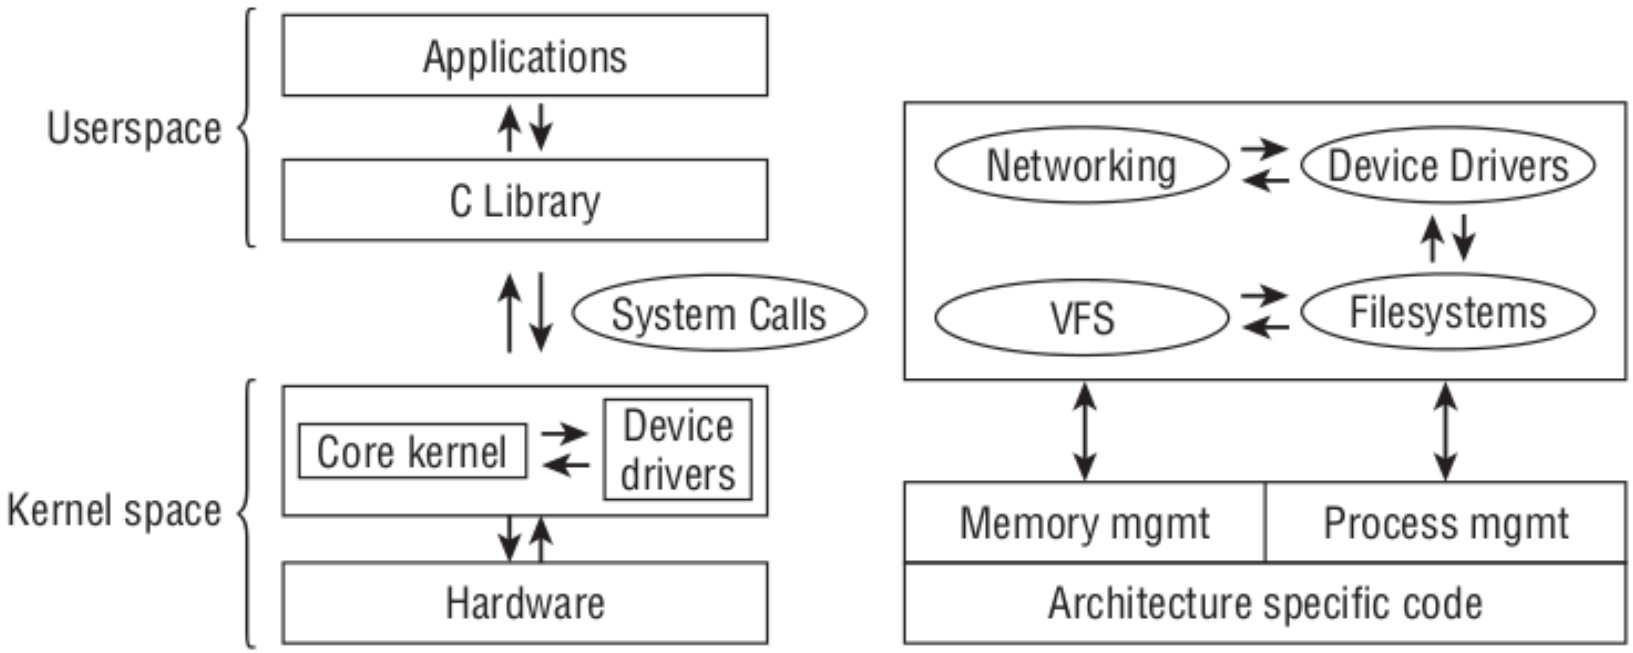

进程与线程的区别与联系

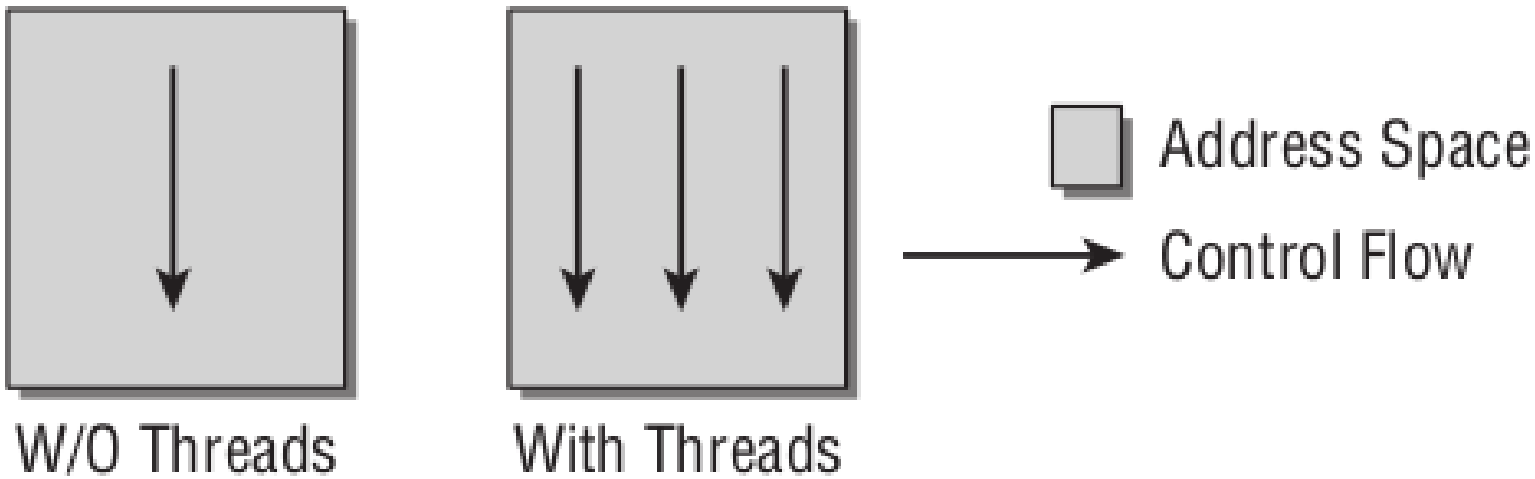

- 进程是资源分配单位（地址空间、I/O等资源）
- 线程是执行单位

Linux中的内核地址空间与用户地址空间

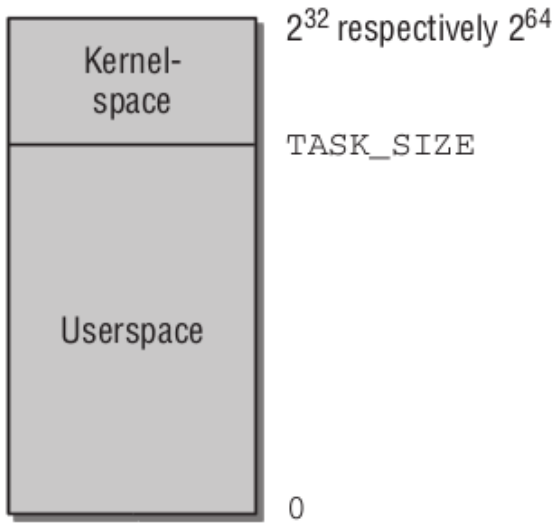

- 用户地址空间从0到TASK_SIZE-1
- 内核地址空间
  从TASK_SIZE到2^{32}-1

Linux中的内核地址空间与用户地址空间

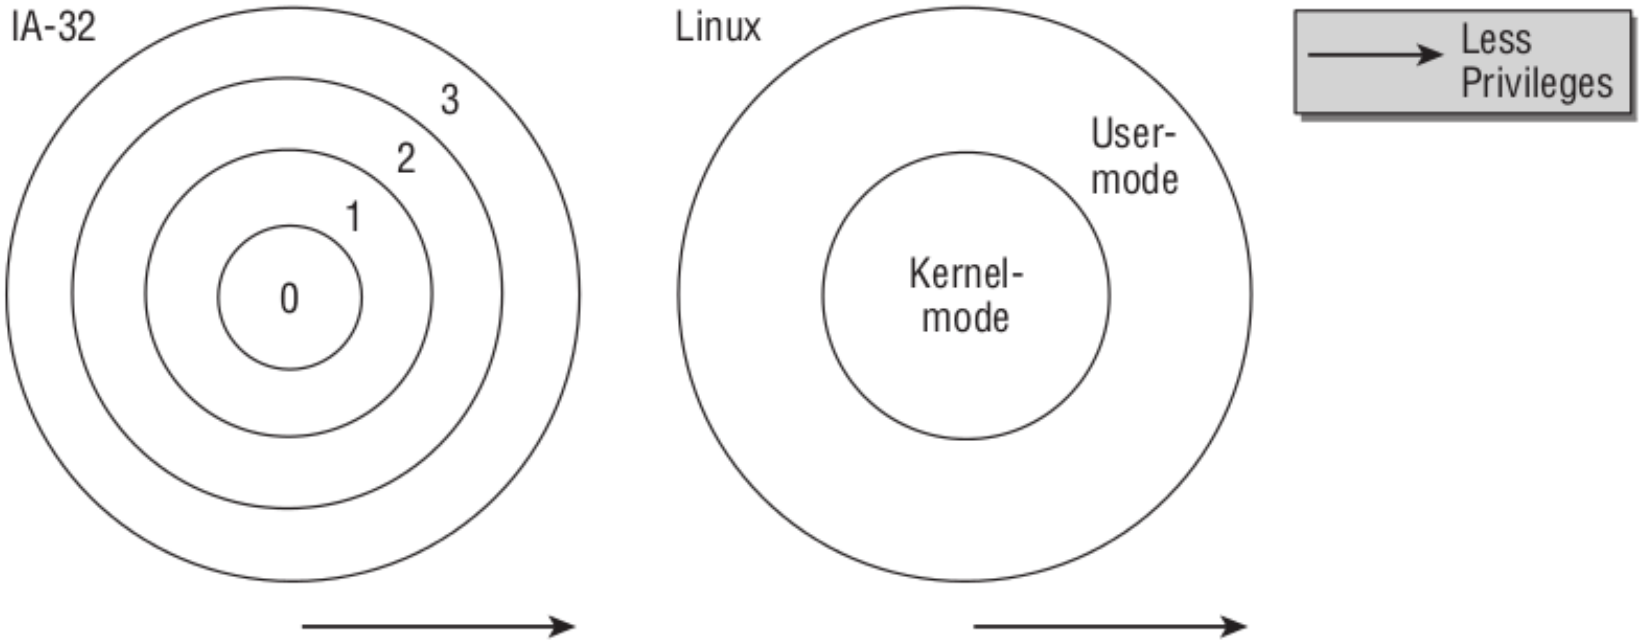

- 用户态下只能访问用户地址空间
- 核心态下可以访问所有地址空间
- 二者其他区别?

分页技术与地址空间共享

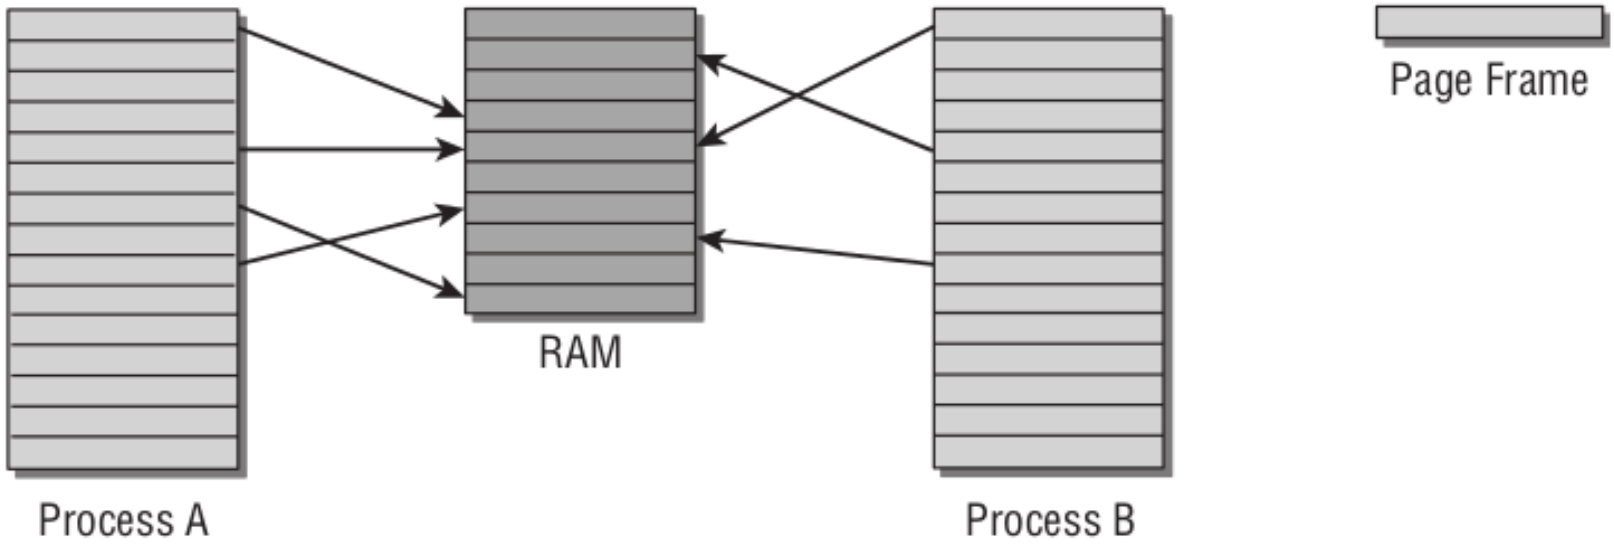

注意观察A、B进程的第0页面对应的物理页框；地址空间的共享（代码、数据）

Linux下的多级分页技术

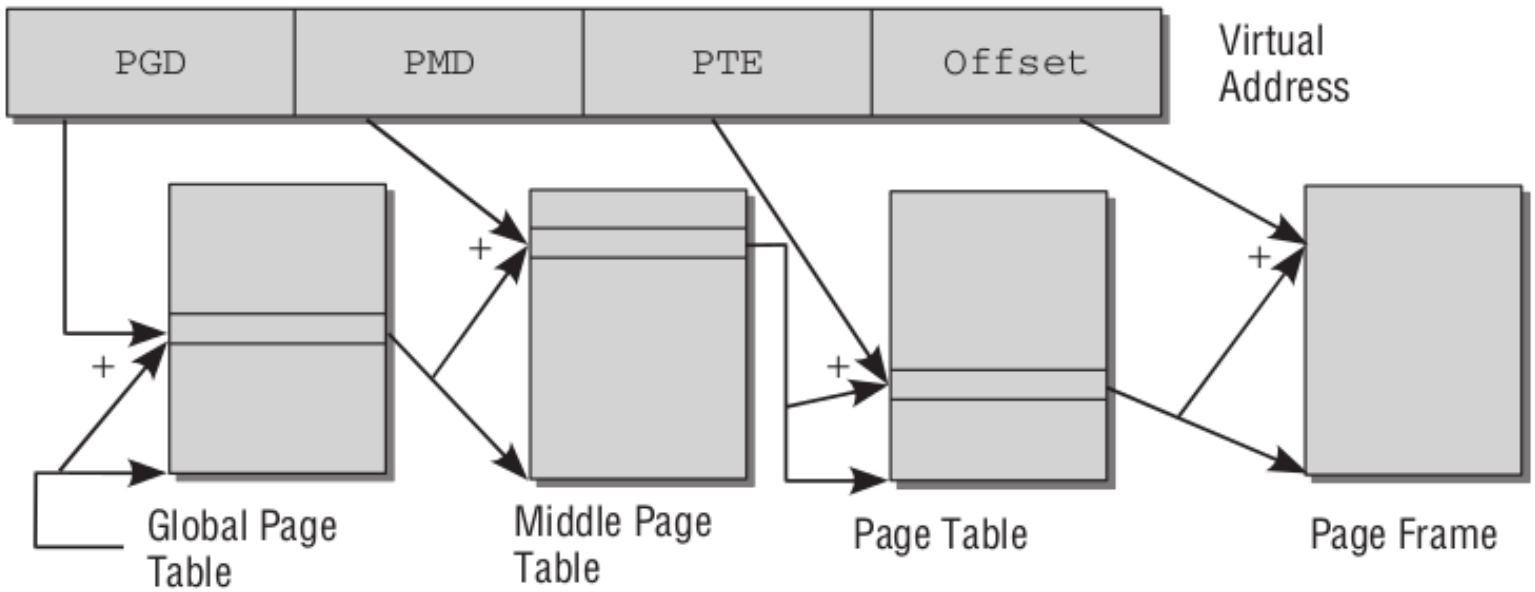

CPU内部进行地址映射的两个硬件单元：MMU/TLB

物理内存的分配算法：伙伴系统

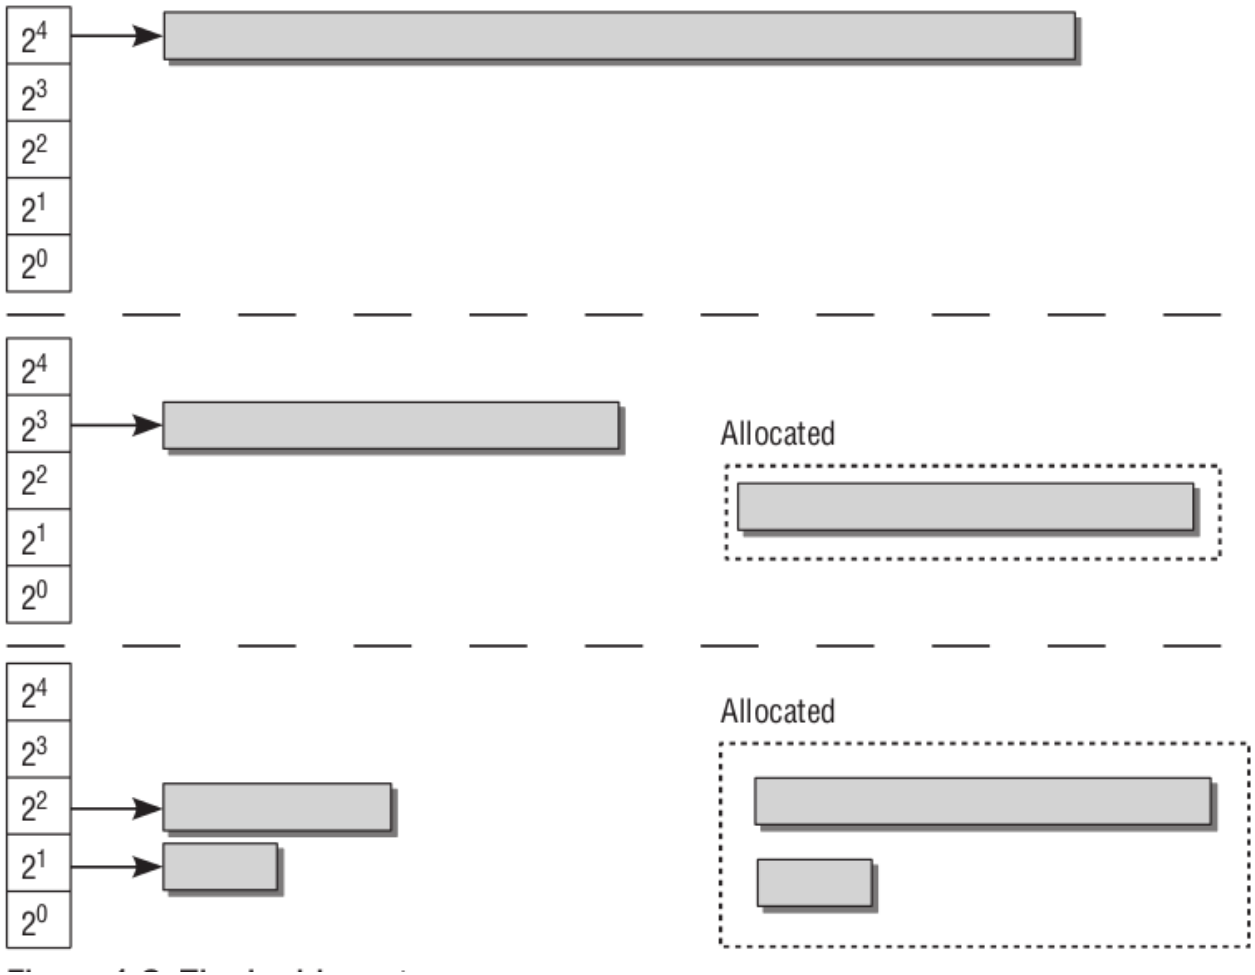

Linux内核关键数据结构：list

list_head的定义

```
struct list_head {
        struct list_head *next, *prev;
};
```

list_head的使用方法：嵌入其它结构

```
struct task_struct {
    ...
    struct list_head run_list;
    ...
};
```

Linux内核关键数据结构：list

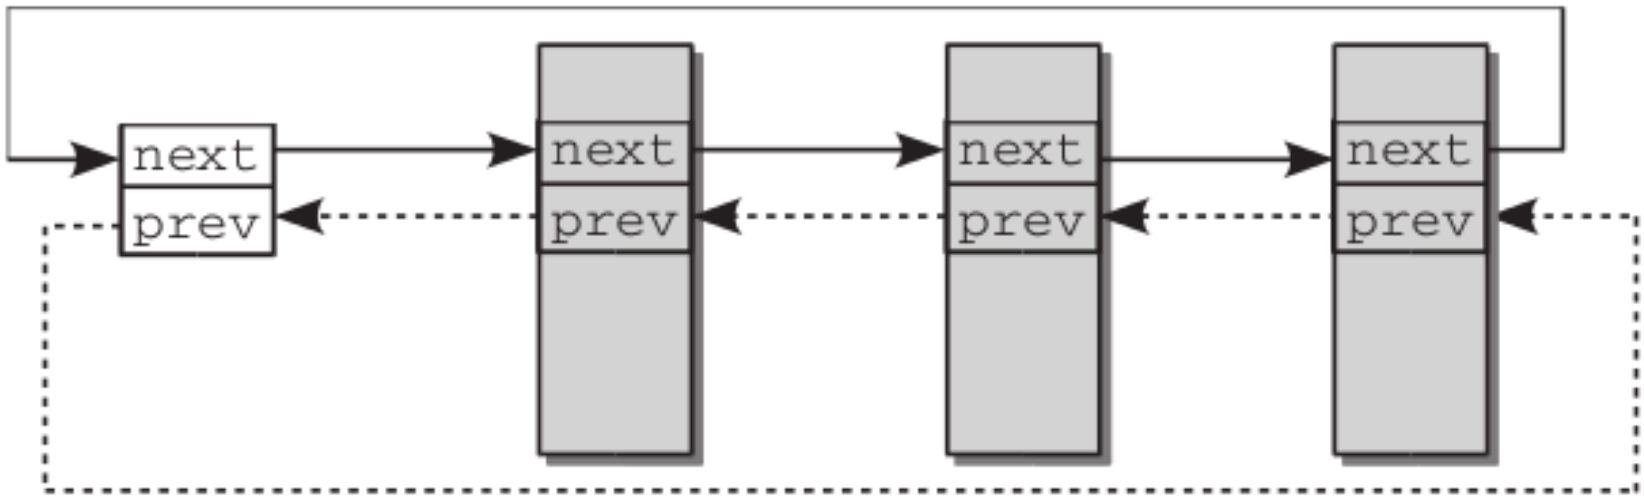

list head的定义

```
#define LIST_HEAD_INIT(name) { &(name), &(name) }

#define LIST_HEAD(name) \
    struct list_head name = LIST_HEAD_INIT(name)
```

针对list结构的操作

list_add(new, head) 把new插入head后面

list_add_tail(new, head) 把new插入head前面

list_del(entry) 把entry从链表中删除

list_empty(head) 判断链表head是否为空

list_splice(list, head) 合并list和head

list_entry(ptr, type, member) 计算包含ptr的结构体的地址

list_for_each(pos, head) 遍历以head为头的链表

针对list结构的操作: 代码分析举例

```
typedef struct list_head list_head;

static inline void list_add(list_head *new,
                            list_head *head)
{
        __list_add(new, head, head->next);
}

static inline void __list_add(list_head *new,
                      list_head *prev,
                      list_head *next)
{
        next->prev = new;
        new->next = next;
        new->prev = prev;
        prev->next = new;
}
```

针对list结构的操作: 代码分析举例

```
struct list_head *p;

list_for_each(p, &list) {
    if (!condition) continue;
    return list_entry(p, struct task_struct, run);
}

return NULL;
```

练习

从源文件include/linux/list.h中找出并理解上述针对list的各种操作函数的定义。

Linux进程表示：task_struct结构

include/linux/sched.h

```
struct task_struct {
    volatile long state;    /* -1 unrunnable */
    void *stack;
    atomic_t usage;
    unsigned int flags; /* per process flags */
    unsigned int ptrace;

    int lock_depth;     /* BKL lock depth */

#ifdef CONFIG_SMP
#ifdef __ARCH_WANT_UNLOCKED_CTXSW
    int oncpu;
#endif
#endif
    ...
};
```

Linux进程表示：task_struct结构

task_struct结构的state字段

```
#define TASK_RUNNING          0
#define TASK_INTERRUPTIBLE    1
#define TASK_UNINTERRUPTIBLE      2
#define TASK_STOPPED          4
#define TASK_TRACED       8
/* in tsk->exit_state */
#define EXIT_ZOMBIE       16
#define EXIT_DEAD         32
/* in tsk->state again */
#define TASK_DEAD         64
```

Linux进程表示：task_struct结构

task_struct结构的rlim字段: include/linux/resource.h

```
struct rlimit {
    unsigned long   rlim_cur;
    unsigned long   rlim_max;
};

struct task_struct {
    ...
    struct rlimit rlim[RLIM_NLIMITS];
    ...
};
```

相关系统调用:

```
int getrlimit(int res, struct rlimit *rlim);
int setrlimit(int res, const struct rlimit *rlim);
```

Linux进程表示：task_struct结构

task_struct结构的rlim字段: include/asm-generic/resource.h

```
#define RLIMIT_CPU        0
#define RLIMIT_FSIZE          1
#define RLIMIT_DATA       2
#define RLIMIT_STACK          3
#define RLIMIT_CORE       4
#define RLIMIT_NOFILE         7
...
#define RLIM_NLIMITS          15
```

相关命令

cat /proc/self/limits

名字空间(namespaces)的概念

传统UNIX只有唯一的名字空间：

PID 进程编号

UID 用户编号

GID 群组编号

唯一名字空间的缺点举例

计算服务提供商：希望为用户提供Linux操作系统的使用服务，每个用户都可以拥有root权限。

解决方法

- 每个用户一台机器?
- 虚拟机(VMWare)?

名字空间(namespaces)的概念

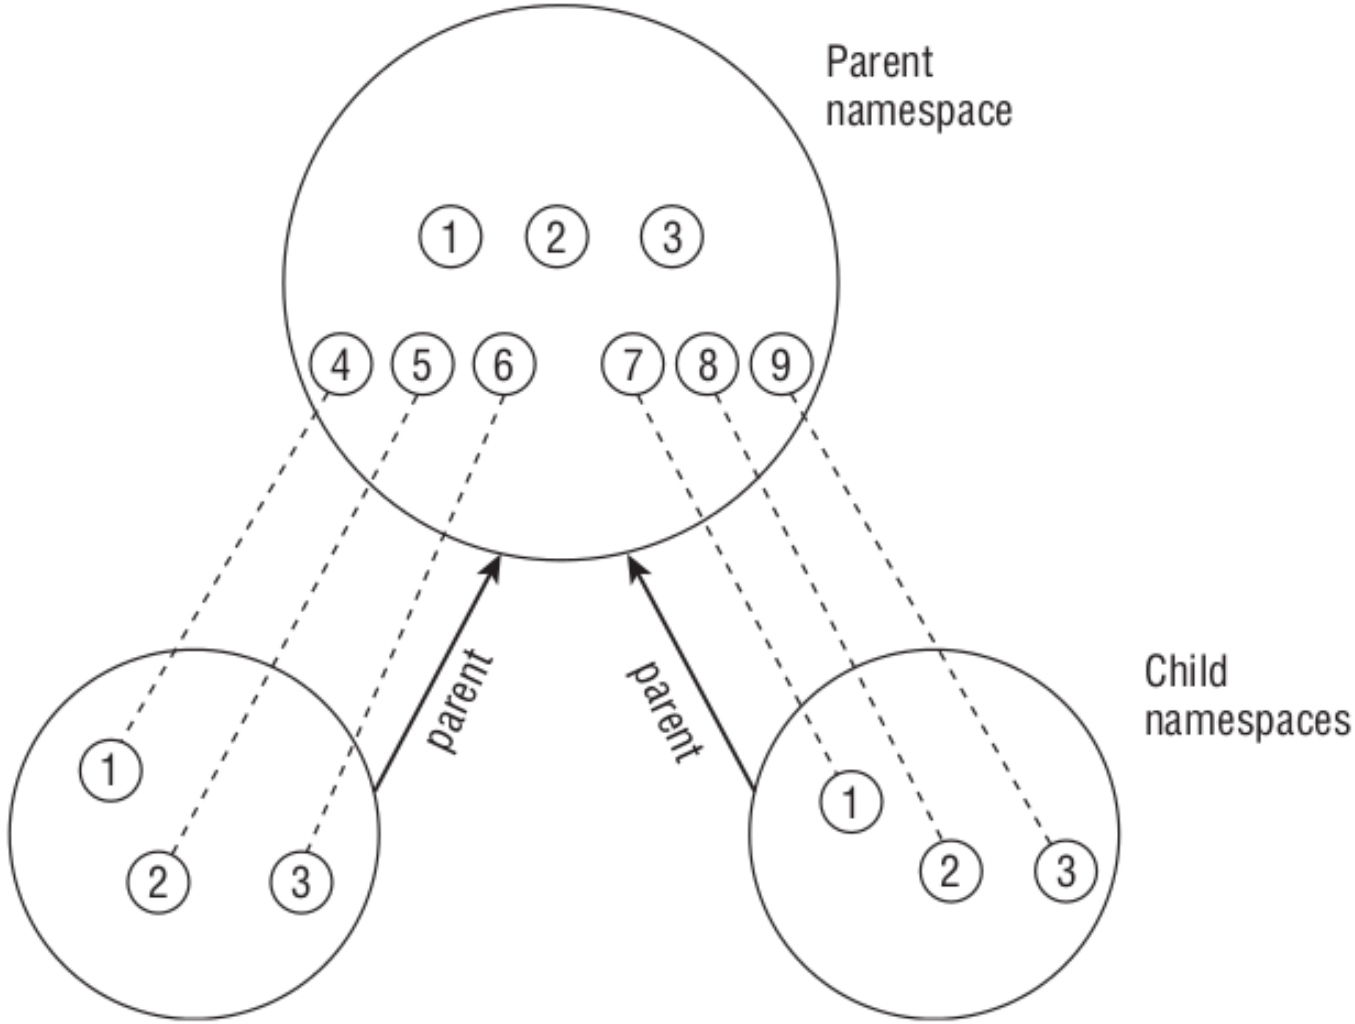

名字空间的相互关系

上图中，子名字空间中的1，2，3编号与父名字空间中的1，2，3完全不相关

Linux内核中名字空间的实现

struct nsproxy: 按照功能划分若干名字空间– include/linux/nsproxy.h

```
struct nsproxy {
    atomic_t count;
    struct uts_namespace *uts_ns;
    struct ipc_namespace *ipc_ns;
    struct mnt_namespace *mnt_ns;
    struct pid_namespace *pid_ns;
    struct user_namespace *user_ns;
    struct net           *net_ns;
};
```

Linux内核中名字空间的实现

struct nsproxy: 按照功能划分若干名字空间– include/linux/sched.h

```
struct task_struct {
    ...
    struct nsproxy *nsproxy;
    ...
}
```

Linux内核中名字空间的实现

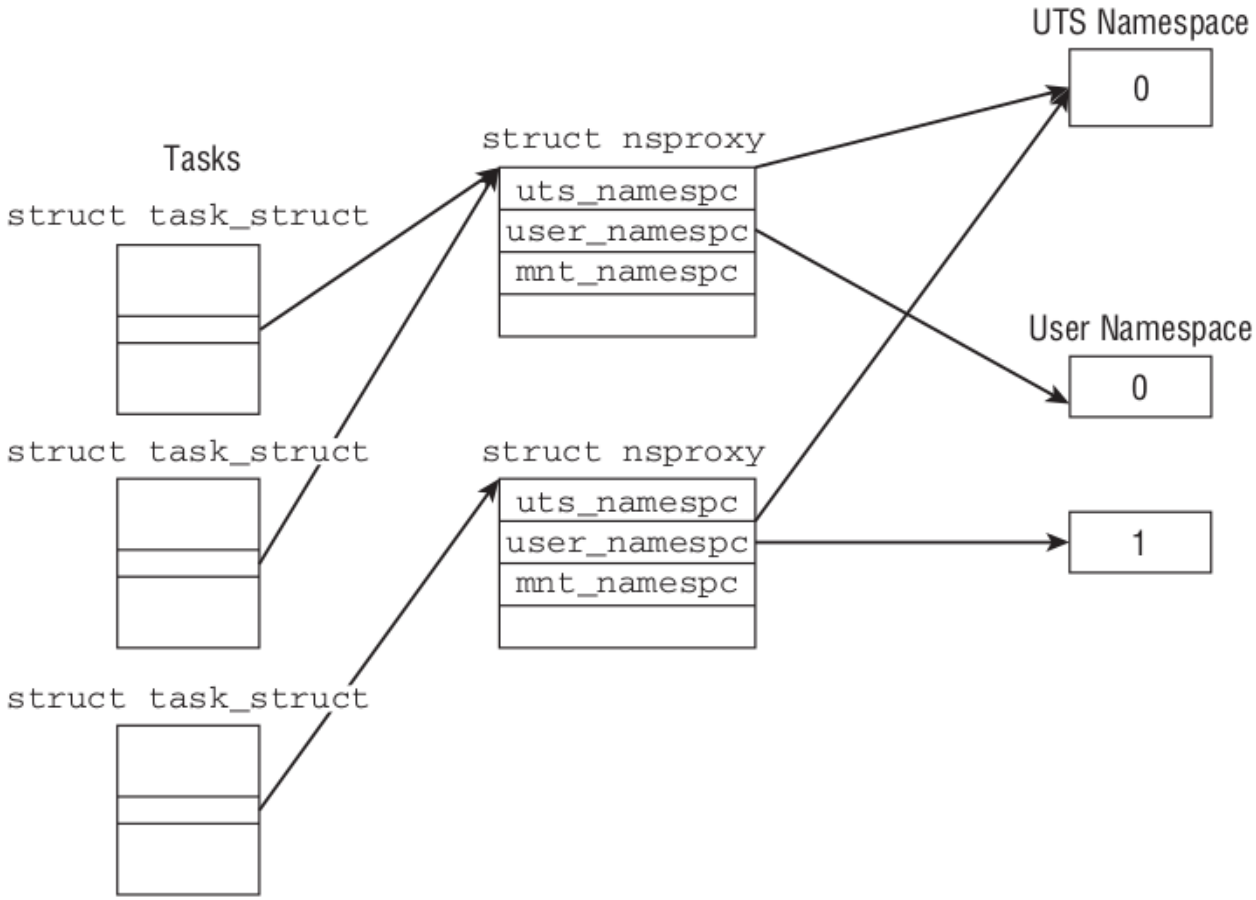

Linux内核中名字空间的实现

fork新进程时可以指明是否为此进程建立新的名字空间：

```
#define CLONE_NEWUTS     0x04000000
#define CLONE_NEWIPC     0x08000000
#define CLONE_NEWUSER    0x10000000
#define CLONE_NEWPID     0x20000000
#define CLONE_NEWNET     0x40000000
```

初始全局名字空间的定义

kernel/nsproxy.c

```
struct nsproxy init_nsproxy = \
        INIT_NSPROXY(init_nsproxy);
```

include/linux/init_task.h

```
#define INIT_NSPROXY(nsproxy) {
    .pid_ns      = &init_pid_ns,                    \
    .count       = ATOMIC_INIT(1),                  \
    .uts_ns      = &init_uts_ns,                    \
    .mnt_ns      = NULL,                        \
    INIT_NET_NS(net_ns)
    INIT_IPC_NS(ipc_ns)                         \
    .user_ns     = &init_user_ns,                   \
}
```

UTS Namespace

include/linux/utsname.h

```
struct uts_namespace {
    struct kref kref;
    struct new_utsname name;
};

struct new_utsname {
    char sysname[65];
    char nodename[65];
    char release[65];
    char version[65];
    char machine[65];
    char domainname[65];
};
```

UTS Namespace的初始值

init/version.c

```
struct uts_namespace init_uts_ns = {
    .kref = {
        .refcount   = ATOMIC_INIT(2),
    },
    .name = {
        .sysname    = UTS_SYSNAME,
        .nodename   = UTS_NODENAME,
        .release    = UTS_RELEASE,
        .version    = UTS_VERSION,
        .machine    = UTS_MACHINE,
        .domainname = UTS_DOMAINNAME,
    },
};
```

User Namespace

include/linux/user_namespace.h

```
struct user_namespace {
    struct kref kref;
    struct hlist_head uidhash_table[UIDHASH_SZ];
    struct user_struct *root_user;
};
```

进程间的相互关系

include/linux/sched.h

```
struct task_struct {
    ...
    struct list_head children; /* children list */
    struct list_head sibling; /* parent's children
    ...
}
```

进程间的相互关系

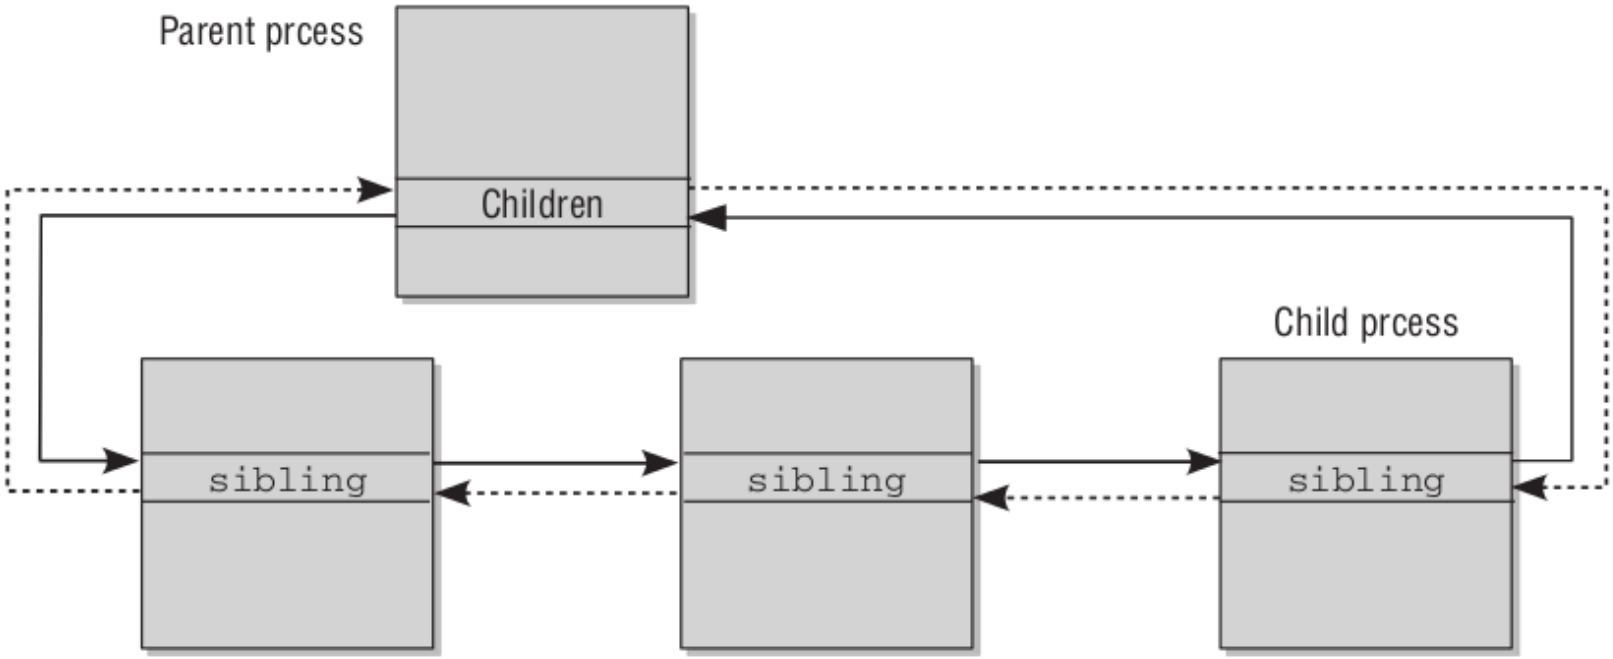

children与sibling

- children是指向本进程所有子进程的链表表头
- sibling用于连接兄弟进程
- pstree命令显示进程结构树(用途?)

创建进程的系统调用

1. fork用于创建新进程
2. vfork创建新进程，并且只有当子进程运行完毕，父进程才能运行；二者共享存储空间(deprecated)
3. clone用于创建进程或者线程

创建进程的系统调用: 写拷贝技术(copy-on-write)

历史上，unix中调用fork创建新进程时，OS需要将父进程的存储空间完全拷贝一份给子进程，这有以下缺点:

- 拷贝内存的过程非常耗时
- 需要占用大量内存空间
- 子进程一旦执行exec，则上述拷贝完全浪费

写拷贝(copy-on-write): 创建新进程时，仅拷贝父进程的页表，并将所有页表项对应的页面设置成只读，只有当父亲或子进程需要写入某页面时，才拷贝相应页面的内容。

创建进程: do_fork函数

kernel/fork.c

```
long do_fork(unsigned long clone_flags,
             unsigned long stack_start,
             struct pt_regs *regs,
             unsigned long stack_size,
             int __user *parent_tidptr,
             int __user *child_tidptr)
```

- clone_flags用于描述进程的哪些属性将被复制(进程/线程!)
- start_stack为用户态下进程的栈起始位置, stack_size为栈的总长度
- regs, parent_tidptr等参数后面讲

创建进程: do_fork函数

arch/x86/kernel/process_32.c

```
asmlinkage int sys_fork(struct pt_regs regs)
{
    return do_fork(SIGCHLD, regs.esp, &regs,
                   0, NULL, NULL);
}
```

创建进程: do_fork函数

arch/x86/kernel/process_32.c

```
asmlinkage int sys_clone(struct pt_regs regs)
{
    unsigned long clone_flags;
    unsigned long newsp;
    int __user *parent_tidptr, *child_tidptr;
    clone_flags = regs.ebx;
    newsp = regs.ecx;
    parent_tidptr = (int __user *)regs.edx;
    child_tidptr = (int __user *)regs.edi;
    if (!newsp)
        newsp = regs.esp;
    return do_fork(clone_flags, newsp, &regs,
                   0, parent_tidptr, child_tidptr);
}
```

创建进程: do_fork函数的实现