

OS概念与Linux内核源代码分析之1

May 21, 2012

本课程Linux内核版本


- ▶ linux kernel: 2.6.11.12
- ▶ 为什么使用这个版本的内核?
- ▶ 下载地址:

<http://www.kernel.org/pub/linux/kernel/v2.6>

为什么研究Linux内核代码

- ▶ 了解OS的概念如何应用于实际操作系统
- ▶ 学习顶尖高手写程序的思路与方法
- ▶ 学习数据结构与算法如何用于解决实际问题
- ▶ (possibly)成为一名内核开发人员

Linux内核整体架构



Linux内核关键数据结构: list

```
struct fox {  
    unsigned long tail_length;  
    unsigned long weight;  
    bool          is_fantastic;  
    struct fox *next;  
    struct fox *prev;  
};
```

思考:

这样定义链表有什么主要缺点?

Linux内核关键数据结构: list


list_head的定义: include/linux/list.h

```
struct list_head {  
    struct list_head *next, *prev;  
};
```

list_head的使用方法: include/linux/sched.h


```
struct task_struct {  
    ...  
    struct list_head run_list;  
    ...  
};
```

Linux内核关键数据结构: list



(a) a doubly linked list with three elements

(b) an empty doubly linked list



Linux内核关键数据结构: list

list_head结构的静态初始化: include/linux/list.h

```
#define LIST_HEAD_INIT(name) \  
    { &(name), &(name) }
```

```
#define LIST_HEAD(name) \  
    struct list_head name =  
    LIST_HEAD_INIT(name)
```


针对list结构的操作

- ▶ `list_add(new, head)` 把new插入head后面
- ▶ `list_add_tail(new, head)` 把new插入head前面
- ▶ `list_del(entry)` 把entry从链表中删除
- ▶ `list_empty(head)` 判断链表head是否为空
- ▶ `list_splice(list, head)` 合并list和head
- ▶ `list_entry(ptr, type, member)` 计算包含ptr的结构体的地址
- ▶ `list_for_each(pos, head)` 遍历以head为头的链表

针对list结构的操作: 代码分析举例

```
typedef struct list_head list_head;

static inline void list_add(list_head *newn,
                             list_head *head)
{
    __list_add(newn, head, head->next);
}

static inline void __list_add(list_head *newn,
                                list_head *prev,
                                list_head *next)
{
    next->prev = newn;
    newn->next = next;
    newn->prev = prev;
    prev->next = newn;
}
```

针对list结构的操作: 代码分析举例

```
struct list_head *p;

list_for_each(p, &list) {
    if (!condition) continue;
    return list_entry(p, struct task_struct,
                     run_list);
}


return NULL;
```

针对list结构的操作: 代码分析举例

课外练习

从源文件include/linux/list.h中找出上述list操作的函数代码，阅读并理解其实现。

Linux内核关键数据结构: hlist_head与hlist_node



用于实现散列表: `include/linux/list.h`

```
struct hlist_head {  
    struct hlist_node *first;  
};  
  
struct hlist_node {  
    struct hlist_node *next, **pprev;  
};
```

Linux内核关键数据结构: hlist_head与hlist_node

思考及课外练习

阅读include/linux/list.h中hlist_add_head(), hlist_del(), hlist_empty(), hlist_add_before()等函数的实现, 思考:

1. hlist_node中的pprev字段指向什么内容?
2. 为什么pprev采用二重指针?
3. 为什么hlist_head中只有一个成员first?

Linux进程描述符: Process Descriptor

task_struct结构: include/linux/sched.h

```
struct task_struct {  
    ...  
    struct list_head tasks;  
    ...  
};
```

系统中所有进程组成的链表

以init.task为表头，进程描述符的tasks字段将所有进程连接起来

遍历系统中所有进程的宏: for_each_process

阅读并理解include/linux/sched.h中for_each_process的实现。

Linux进程描述符: Process Descriptor

```
struct task_struct {  
    ...  
    int prio, static_prio;  
    struct list_head run_list;  
    prio_array_t *array;  
    ...  
};
```

各字段的含义

- ▶ `prio` 为进程当前优先级(0 – 139)
- ▶ `run_list` 用于连接所有相同优先级的进程
- ▶ `array`?

Linux进程描述符: Process Descriptor

kernel/sched.c

```
struct prio_array {  
    unsigned int nr_active;  
    unsigned long bitmap[BITMAP_SIZE];  
    struct list_head queue[MAX_PRIO];  
};
```

各成员字段的含义

- ▶ **nr_active**: 当前列表中进程总数
- ▶ **bitmap** 用于记录哪个队列为非空
- ▶ **queue**用于存储140个队列的表头

Linux进程描述符: Process Descriptor

```
void enqueue_task(struct task_struct *p,  
                  prio_array_t *array)  
{  
    sched_info_queued(p);  
    list_add_tail(&p->run_list,  
                  array->queue[p->prio]);  
    __set_bit(p->prio, array->bitmap);  
    array->nr_active++;  
    p->array = array;  
}
```

课外练习

1. 上页中，**BITMAP_SIZE**和**MAX_PRIO**两个宏分别在文件`kernel/sched.c`和`include/linux/sched.h`中定义，请确定这两个宏的具体数值。
2. 在文件`kernel/sched.c`找出`dequeue_task`的定义并理解它。

Linux进程描述符: Process Descriptor

task_struct结构: include/linux/sched.h

```
struct task_struct {  
    volatile long state;  
    ...  
};
```

进程可能的状态: include/linux/sched.h

```
#define TASK_RUNNING          0  
#define TASK_INTERRUPTIBLE    1  
#define TASK_UNINTERRUPTIBLE  2  
#define TASK_STOPPED          4  
#define TASK_TRACED           8  
#define TASK_DEAD             64
```

Linux进程描述符: Process Descriptor

改变进程状态的函数/宏

- ▶ `set_task_state` 改变指定进程的状态
- ▶ `set_current_state` 改变当前执行的进程的状态


课外练习

阅读以上两个函数的源代码(位于文件`include/linux/sched.h`), 并思考为什么要这样写。

Linux进程表示: task_struct结构

```
struct task_struct {  
    ...  
    struct task_struct *real_parent;  
    struct task_struct *parent;  
    struct list_head children;  
    struct list_head sibling;  
    ...  
};
```

Linux进程表示: task_struct结构



Linux进程表示: `task_struct`结构

查看进程结构树的命令: `ps tree`

Linux进程表示: task_struct结构

```
struct task_struct {  
    ...  
    struct task_struct *group_leader;  
    pid_t tgid;  
    struct list_head ptrace_children;  
    struct list_head ptrace_list;  
    struct signal_struct *signal;  
    ...  
};
```

Linux进程表示: task_struct结构

```
struct signal_struct {  
    ...  
    /* job control IDs */  
    pid_t pgrp;  
    pid_t session;  
    ...  
};
```


Linux进程表示: task_struct结构

```
enum pid_type
{
    PIDTYPE_PID,
    PIDTYPE_TGID,
    PIDTYPE_PGID,
    PIDTYPE_SID,
    PIDTYPE_MAX
};
```


Linux进程表示: task_struct结构

```
struct pid
{
    int nr;
    struct hlist_node pid_chain;
    struct list_head pid_list;
};
```

Linux进程表示: task_struct结构



Linux进程表示: task_struct结构



Linux进程表示: task_struct结构

```
struct __wait_queue_head {  
    spinlock_t lock;  
    struct list_head task_list;  
};  
typedef struct __wait_queue_head  
    wait_queue_head_t;
```

Linux进程表示: task_struct结构

```
struct __wait_queue {  
    unsigned int flags;  
    struct task_struct * task;  
    wait_queue_func_t func;  
    struct list_head task_list;  
};
```


Linux进程表示: task_struct结构

task_struct结构的rlim字段: include/linux/resource.h

```
struct rlimit {
    unsigned long    rlim_cur;
    unsigned long    rlim_max;
};

struct task_struct {
    ...
    struct rlimit rlim[RLIM_NLIMITS];
    ...
};
```

相关系统调用:

```
int getrlimit(int res, struct rlimit *rlim);
int setrlimit(int res, const struct rlimit *rlim);
```

Linux进程表示: task_struct结构

task_struct结构的rlim字段:
include/asm-generic/resource.h

```
#define RLIMIT_CPU          0
#define RLIMIT_FSIZE        1
#define RLIMIT_DATA         2
#define RLIMIT_STACK        3
#define RLIMIT_CORE         4
#define RLIMIT_NOFILE       7
...
#define RLIM_NLIMITS        15
```

相关命令

cat /proc/self/limits

创建进程的系统调用

1. `fork`用于创建新进程
2. `vfork`创建新进程，并且只有当子进程运行完毕，父进程才能运行；二者共享存储空间(deprecated)
3. `clone`用于创建进程或者线程

创建进程的系统调用: 写拷贝技术(copy-on-write)

历史上, **unix**中调用**fork**创建新进程时, **OS**需要将父进程的存储空间完全拷贝一份给子进程, 这有以下缺点:

- ▶ 拷贝内存的过程非常耗时
- ▶ 需要占用大量内存空间
- ▶ 子进程一旦执行**exec**, 则上述拷贝完全浪费

写拷贝(**copy-on-write**): 创建新进程时, 仅拷贝父进程的页表, 并将所有页表项对应的页面设置成只读, 只有当父亲或子进程需要写入某页面时, 才拷贝相应页面的内容。

创建进程: do_fork函数

kernel/fork.c

```
long do_fork(unsigned long clone_flags,  
             unsigned long stack_start,  
             struct pt_regs *regs,  
             unsigned long stack_size,  
             int __user *parent_tidptr,  
             int __user *child_tidptr)
```

- ▶ **clone_flags**用于描述进程的哪些属性将被复制(进程/线程!)
- ▶ **start_stack**为用户态下进程的栈起始位置, **stack_size**为栈的总长度
- ▶ **regs, parent_tidptr**等参数后面讲

创建进程: do_fork函数

arch/x86/kernel/process_32.c

```
asmlinkage int sys_fork(struct pt_regs regs)
{
    return do_fork(SIGCHLD, regs.esp, &regs,
                   0, NULL, NULL);
}
```

创建进程: do_fork函数

arch/x86/kernel/process_32.c

```
asmlinkage int sys_clone(struct pt_regs regs)
{
    unsigned long clone_flags;
    unsigned long newsp;
    int __user *parent_tidptr, *child_tidptr;
    clone_flags = regs.ebx;
    newsp = regs.ecx;
    parent_tidptr = (int __user *)regs.edx;
    child_tidptr = (int __user *)regs.edi;
    if (!newsp)
        newsp = regs.esp;
    return do_fork(clone_flags, newsp, &regs,
                  0, parent_tidptr, child_tidptr);
}
```