OS概念与Linux内核代码分析之一: 进程管理

李中国

苏州大学计算机科学与技术学院

May 29, 2012

内容提要

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head 哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块, 进程描述符 进程描述符各字段分析

内容提要

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head 哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块, 进程描述符 进程描述符各字段分析

内容提要

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head 哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块, 进程描述符 进程描述符

本课程Linux内核版本

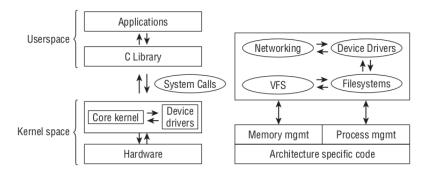
- ▶ linux kernel: 2.6.11.12
- ▶ 为什么使用这个版本的内核?
- ▶ 下载地址:

http://www.kernel.org/pub/linux/kernel/v2.6

为什么研究Linux内核代码

- ▶ 了解OS的概念如何应用于实际操作系统
- ▶ 学习顶尖高手写程序的思路与方法
- ▶ 学习数据结构与算法如何用于解决实际问题
- ▶ 学习大规模工程的设计与实施
 - ▶ 2.6.x内核开发成本: \$1.14 billion USD (欧盟)
 - ► 最新内核开发成本: \$3.0 billion USD (Wikipedia)
- ▶ 成为一名内核开发人员

Linux内核整体架构



Outline

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head

哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块, 进程描述符 进程描述符各字段分析

双向链表的常见实现方式

```
struct fox {
   unsigned long tail_length;
   unsigned long weight;
            is fantastic;
   bool
   struct fox *next;
   struct fox *prev;
};
思考:
这样定义链表有什么主要缺点?
```

list_head的定义

```
include/linux/list.h
struct list_head {
    struct list_head *next, *prev;
};

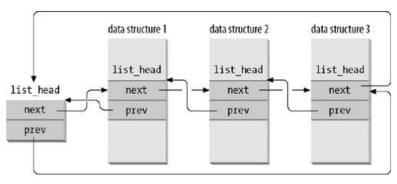
思考
这种只有指针而没有数据的list_head能有什么用处?
```

list_head的使用方法举例

```
include/linux/sched.h
struct task_struct {
    ...
    struct list_head run_list;
    ...
};

B考
与fox结构相比,使用list_head构造链表有什么好处?
```

用list_head实现双向循环链表: 示意图



(a) a doubly linked listed with three elements



用list_head实现双向链表: 关键问题

```
include/linux/list.h
struct list head {
    struct list head *next, *prev;
};
include/linux/sched.h.
struct task_struct {
    struct list_head run_list;
};
```

关键问题

如何根据list_head的地址确定包含它的数据结构的地址?

如何计算包含list_head的结构体地址?

宏list_entry(ptr, type, member) 计算包含ptr(指向list_head结构的指针)的结构体的地址

例子: 结合上述task_struct结构 list_entry(ptr, struct task_struct, run_list)

思考 宏list_entry的实现原理是什么?

如何计算包含list_head的结构体地址?

include/linux/list.h

```
#define list_entry(ptr, type, member) \
    container_of(ptr, type, member)
```

container_of的定义 请在include/linux/kernel.h中找到container_of的定义并试着理解 它。

list_head结构的静态初始化

LIST_HEAD的使用方法

例:LIST_HEAD(packet_list)声明一个名为packet_list的表头变量并将其初始化为空表。

针对list结构的操作

- ▶ list_add(new, head) 把new插入head后面
- ▶ list_add_tail(new, head) 把new插入head前面
- ▶ list_del(entry) 把entry从链表中删除
- ▶ list_empty(head) 判断链表head是否为空
- ▶ list_splice(list, head) 合并list和head
- ▶ list_for_each(pos, head) 遍历以head为头的链表
- ▶ list_for_each_entry(pos, head)

针对list结构的操作举例: list_add typedef struct list_head list_head; static inline void list_add(list_head *new, list head *head) list add(new, head, head->next); **static** inline **void** list add(list head *new, list head *prev, list head *next) next->prev = new; new->next = next;new->prev = prev; prev->next = new;

针对list结构的操作举例: list_for_each

针对list结构的操作: 其它

课外练习

从源文件include/linux/list.h中找出上述list操作的函数代码,阅读并理解其实现。

Outline

本部分课程简介

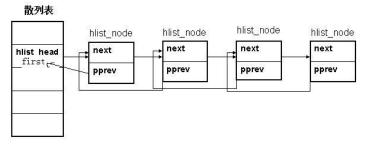
Linux内核关键数据结构

双向循环链表: list_head

哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块, 进程描述符 进程描述符各字段分析

实现哈希表: hlist_head与hlist_node



```
include/linux/list.h
struct hlist_head {
    struct hlist_node *first;
};
struct hlist_node {
    struct hlist_node *next, **pprev;
};
```

针对hlist_head与hlist_node的操作

- ▶ hlist_add_head
- ▶ hlist_add_before
- ► hlist_del(entry)
- ► hlist_empty(head)
- ► hlist_entry(head)
- ► hlist_for_each_entry(pos, head)

Linux内核关键数据结构: hlist_head与hlist_node

思考及课外练习

阅读include/linux/list.h中hlist_add_head(), hlist_del(), hlist_empty(), hlist_add_before()等函数的实现,思考:

- 1. hlist_node中的pprev字段指向什么内容?
- 2. 为什么pprev采用二重指针?
- 3. 为什么hlist_head中只有一个成员first?
- 4. hlist_head可否直接用hlist_node代替?

实现哈希表: hlist_head与hlist_node

```
include/linux/list.h
static inline void hlist_add_before(
                    struct hlist_node *n,
                    struct hlist node *next)
    n->pprev = next->pprev;
    n->next = next;
    next->pprev = &n->next;
    *(n->pprev) = n;
}
```

要理解这其中四条语句特别是最后一条的含义。

Outline

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head 哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块,进程描述符 进程描述符各字段分析

进程控制块(PCB)

用于存放与每个进程相关的信息

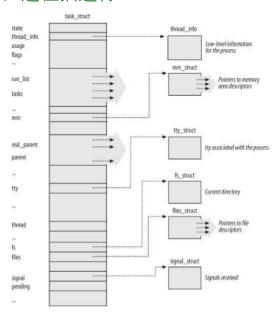
- ▶ 进程状态
- ▶ 程序计数器PC
- ► CPU寄存器
- ► CPU调度信息
- ▶ 内存管理信息
- ▶ I/O状态信息
- ▶ 记账信息

process state
process number
program counter
registers
memory limits
list of open files
• • •

Linux进程描述符

- ► 进程控制块在Linux内核中被成为进程描述符(Process Descriptor)
- ► 结构名字: struct task_struct;
- ▶ 这是一个非常大的数据结构, 其中包含:
 - ▶ 94行成员字段
 - ▶ 其中36行成员本身又是struct或者指向struct的指针
- ▶ 后面我们将对task_struct结构进行逐行分析

Linux进程描述符



Outline

本部分课程简介

Linux内核关键数据结构 双向循环链表: list_head 哈希表: hlist_head与hlist_node

Linux进程描述符task_struct 进程控制块,进程描述符 进程描述符各字段分析

Linux区别进程的方式: pid字段

- ▶ 在内核中,对进程的各种操作均通过task_struct实现
- ► 用户角度,每个进程有唯一编号(PID). 进程的PID保存于task_struct的pid字段中。
 - ▶ 例如: kill()系统调用的参数为PID
 - ▶ 内核需要快速从PID找到对应的task_struct进行操作(后面讲具体方法)

PID可取的最大值: include/linux/threads.h

```
/*
 * This controls the default maximum pid
 * allocated to a process
 */
#define PID_MAX_DEFAULT 0x8000
```

Linux区别进程的方式: pid字段

思考

- 1. 为什么要限制PID可取的最大值?
- 2. 如果系统中进程个数超过这个最大值怎么办?

Linux区别进程的方式: pid字段

```
pidmap_array用于管理pid值的回收利用: kernel/pid.c
typedef struct pidmap {
    atomic t nr free;
    void *page;
} pidmap_t;
static pidmap_t pidmap_array[PIDMAP_ENTRIES] =
     \{ [0 \dots PIDMAP\_ENTRIES-1] =
       { ATOMIC INIT(BITS PER PAGE), NULL } };
思考
pidmap array的必要性? (从pid分配的角度考虑)
```

内核遍历所有进程的方式: tasks字段

OS有时需要遍历系统中全部进程,所以进程描述符中需要相应 字段,用于连接系统中的各个进程。

- ▶ 这就用到前面所说的list_head这个关键结构
- ▶ 回想一下list_head中包含的两个字段

内核遍历所有进程的方式: tasks字段

系统中所有进程组成的链表以init_task为表头,进程描述符的tasks字段将所有进程连接起来遍历系统中所有进程的宏: for_each_process阅读并理解include/linux/sched.h中for_each_process的实现。

与进程调度相关的字段

在进程调度时,需要从处于TASK_RUNNING(可运行)状态的进程中选择一个,让它占有CPU并运行。

2.6.x之前的Linux内核

将所有处于 $TASK_RUNNING$ 状态的进程放到一个链表,需要遍历整个链表,从中选择优先级最高的进程。调度的时间复杂度为O(n).

Linux 2.6.x内核的O(1)调度算法

- ▶ 在进程描述符中记录每个进程的优先级
- ▶ 以有效的数据结构按照优先级组织所有进程
- ▶ 调度算法时间复杂度为O(1), 与进程数n没有直接关系

与进程调度相关的字段

```
struct task_struct {
    ...
    int prio, static_prio;
    struct list_head run_list;
    prio_array_t *array;
    ...
};
```

各字段的含义

- ▶ prio 为进程当前优先级(0 139)
- ▶ run_list 用于连接所有相同优先级的进程
- array?

与进程调度相关的字段

```
kernel/sched.c
struct prio array {
    unsigned int nr_active;
    unsigned long bitmap[BITMAP_SIZE];
    struct list_head queue[MAX_PRIO];
};
include/linux/sched.h
typedef struct prio_array prio_array_t;
各成员字段的含义
```

- ▶ nr_active: 当前列表中进程总数
- ▶ bitmap 用于记录哪个队列为非空(后面分析调度算法时用到)
- ▶ queue用于存储140个队列的表头

与进程调度相关的字段

```
void enqueue_task(struct task_struct *p,
                  prio array_t *array)
    sched_info_queued(p);
    list_add_tail(&p->run_list,
                  array->queue[p->prio]);
    set bit(p->prio, array->bitmap);
    array->nr active++;
    p->array = array;
特别注意
list add tail的第一个参数.
```

课外练习

- 1. 上页中,BITMAP_SIZE和MAX_PRIO两个宏分别在文件kernel/sched.c和include/linux/sched.h中定义,请确定这两个宏的具体数值。
- 2. 在文件kernel/sched.c找出dequeue_task的定义并理解它。

表示进程状态的字段: state

```
include/linux/sched.h.
struct task_struct {
        volatile long state;
};
进程可能的状态: include/linux/sched.h
#define TASK_RUNNING
#define TASK INTERRUPTIBLE
#define TASK UNINTERRUPTIBLE
#define TASK STOPPED
#define TASK_TRACED
#define TASK DEAD
                         64
```

表示进程状态的字段: state

改变进程状态的函数/宏

- ▶ set_task_state 改变指定进程的状态
- ▶ set_current_state 改变当前执行的进程的状态

课外练习

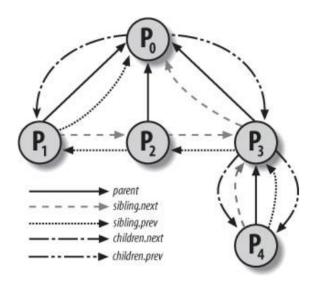
阅读以上两个函数的源代码(位于文件include/linux/sched.h),并思考为什么要这样写。

记录进程之间层次关系的字段

```
进程管理中需要记录进程之间的层次关系(父母、兄弟姐妹).

struct task_struct {
    ...
    struct task_struct *real_parent;
    struct task_struct *parent;
    struct list_head children;
    struct list_head sibling;
    ...
};
```

记录进程之间层次关系的字段



记录进程之间层次关系的字段

查看进程结构树的命令: pstree

除了上述关系外, 进程之间还存在如下关系:

- ► 多个进程可以形成一个组(group),每个组都有唯一的leader.
 - ▶ 例如: cat file | grep 'abc' | wc -1, 其中三个 进程形成一个组
- ► 类似,进程间可以形成一个会话(session),每个会话中指定 唯一的leader
- ► 同一进程创建的多个线程组成线程组(thread group),每组也有唯一leader
 - ▶ 线程组对应多线程程序里的所有线程

 $task_struct$ 中的 $group_leader$ 和tgid分别表示该进程所在的进程组的leader、线程组的leader:

```
struct task_struct {
    ...
    struct task_struct *group_leader;
    pid_t tgid;
    pid_t pid;
    struct signal_struct *signal;
    ...
};
```

```
pgrp和session字段分别表示进程组leader的PID、会话
组leader的PID:
include/linux/sched.h
struct signal_struct {
    /* job control IDs */
    pid_t pgrp;
    pid_t session;
};
```

进程标识:

- ▶ 从内核角度,一律通过task_struct操作进程
- ▶ 从用户角度可能需要通过PID操作进程,如kill(pid)

所以需要做到从pid到task_struct的快速转换:

- ▶ task_struct到pid: p->pid
- ▶ pid到task_struct的快速转换:
 - ▶ 遍历所有进程,逐一检查其pid字段的值?
 - ▶ 通过散列表结构做到快速转换
- ▶ (重要)给定进程组、会话组或者线程组的leader ID, 如何快速找出该组中所有进程(线程)?

共有四种类型的PID: 进程本身PID、线程组leader的PID、进程组leader的PID以及会话组leader的PID:

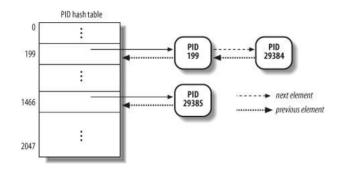
```
include/linux/pid.h
enum pid type
    PIDTYPE_PID,
    PIDTYPE_TGID,
    PIDTYPE PGID,
    PIDTYPE_SID,
    PIDTYPE MAX
};
依据PID类型不同,共定义四个散列表: kernel/pid.c
static struct hlist_head
   *pid_hash[PIDTYPE_MAX];
```

散列表中元素struct pid: include/linux/pid.h

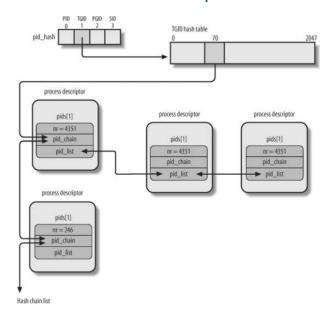
```
struct pid
    int nr;
    struct hlist_node pid_chain;
    struct list_head pid_list;
};
task struct中相应字段
struct task struct
    /* PID/PID hash table linkage. */
    struct pid pids[PIDTYPE_MAX];
};
```

```
哈希函数的定义
unsigned long hash_long(unsigned long val,
    unsigned int bits)
{
    unsigned long hash = val * 0x9e370001UL;
    return hash >> (32 - bits);
}
```

表示进程其他关系的字段: 简单哈希表示意图



表示进程其他关系的字段: pid_hash结构图



处于等待态的进程如何组织

Linux中等待态进程的表示

- ► TASK_INTERRUPTIBLE
- ► TASK_UNINTERRUPTIBLE

进入等待态的原因(所要等待的事件)

- ▶ 等待磁盘操作结束
- ▶ 等待固定时间(如**1**秒)
- ▶ 等待互斥锁的释放
- ▶ 等待其他临界资源
- ▶ ..

处于等待态的进程如何组织: 等待队列

等待队列(wait queue)

把等待同一事件的进程放到一个等待队列中去。一旦所等待的事件发生,则可以唤醒该队列中的进程。

wait queue表头的定义: include/linux/wait.h

```
struct __wait_queue_head {
    spinlock_t lock;
    struct list_head task_list;
};
```

其中,字段lock用来实现对等待队列的互斥访问(因为内核中有多个地方可能需要对该队列进程操作)。

处于等待态的进程如何组织: 等待队列中的元素

```
include/linux/wait.h
struct __wait_queue {
    unsigned int flags;
    struct task_struct * task;
    wait_queue_func_t func;
    struct list_head task_list;
};
```

- ► flags表示该进程等待的事件是否为exclusive
- ▶ task为进入等待队列的进程
- ▶ func为唤醒该进程的方式(函数)
- ▶ task_list用于将所有进程连接成队列

处于等待态的进程如何组织

exlusive进程和non-exlusive进程

- ▶ exlusive进程: 该进程等待的资源不能共享, flags设为1
 - ▶ 例如该进程等待的是进入临界区的机会
- ► non-exclusive进程: 该进程等待的事件/资源可以共享, flags设为0
 - ▶ 例如该进程等待的是磁盘数据传输

思考

为什么将**flags**放到__wait_queue而不是放 到__wait_queue_head中去**?**

对等待队列(wait queue)的操作: 初始化

include/linux/wait.h

- ► DECLARE_WAIT_QUEUE_HEAD (name) 声明名为**name**的队 头并初始化
- ▶ init_waitqueue_head(q)对动态分配的队头q初始化
- ▶ init_waitqueue_entry(p,q)对队列元素q初始化:

```
q->flags = 0;
q->task = p;
q->func = default_wake_function;
```

► DEFINE_WAIT (name) 将当前占有CPU的进程封装为名为name的队列元素

课外练习

阅读并理解上述对队列头和队列元素初始化的函数或者宏。

对等待队列的操作: 队列元素的插入和删除

kernel/wait.c

- ▶ add_wait_queue(q, wait)
- ▶ add_wait_queue_exclusive(q, wait)
- ▶ remove_wait_queue(q, wait)
- ▶ waitqueue_active(q) 功能是什么? (include/linux/wait.h)

- ▶ sleep_on
- ► interruptible_sleep_on
- ► sleep_on_timeout
- ▶ interruptible_sleep_on_timeout

```
void sleep_on(wait_queue_head_t *wq)
{
    wait_queue_t wait;
    init_waitqueue_entry(&wait, current);
    current->state = TASK_UNINTERRUPTIBLE;
    add_wait_queue(wq, &wait);
    schedule();
    remove_wait_queue(wq, &wait);
}
```

- ▶ prepare_to_wait
- ▶ prepare_to_wait_exclusive
- ▶ finish_wait

```
DEFINE_WAIT(wait);
prepare_to_wait(&wq,&wait,TASK_INTERRUPTIBLE);
...
if (!condition)
    schedule();
finish_wait(&wq, &wait);
```

对等待队列的操作: wait_event(condtion)

对等待队列的操作:如何把队列中的进程唤醒?

- ▶ wake_up
- ▶ wake_up_nr
- ▶ wake_up_all
- ▶ wake_up_interruptible
- ▶ wake_up_interruptible_nr
- ▶ wake_up_interruptible_all
- ▶ wake_up_interruptible_sync
- ▶ wake_up_locked

对等待队列的操作: 如何把队列中的进程唤醒?

- ▶ 所有non-exclusive的进程都被唤醒
- ► 如果名字中没有interruptible,则唤醒所有睡眠进程(TASK_INTERRUPTIBLE及TASK_UNINTERRUPTIBLE).否则,只唤醒队列中TASK_INTERRUPTIBLE状态的进程。
- ▶ 名字中含有nr的宏唤醒指定个数的exclusive进程
- ▶ 名字中含有all的宏唤醒全部指定状态的exclusive进程
- ► 名字中没有nr或者all的宏只唤醒一个exclusive进程

task_struct结构的rlim字段: include/linux/resource.h

```
struct rlimit {
    unsigned long rlim_cur;
    unsigned long rlim max;
};
struct task struct {
    struct rlimit rlim[RLIM NLIMITS];
};
相关系统调用:
```

int getrlimit(int res, struct rlimit *rlim);
int setrlimit(int res, const struct rlimit *rlim);

task_struct结构的rlim字段: include/asm-generic/resource.h

```
#define RLIMIT_CPU 0
#define RLIMIT_FSIZE 1
#define RLIMIT_DATA 2
#define RLIMIT_STACK 3
#define RLIMIT_CORE 4
#define RLIMIT_NOFILE 7
...
#define RLIM_NLIMITS 15
```

相关命令 cat /proc/self/limits

```
struct task_struct {
    ...
    struct user_struct thread;
    ...
};
```

```
include/asm-x86_64/processor.h
struct thread_struct {
    unsigned long    rsp0;
    unsigned long    rsp;
    unsigned long    fs;
    unsigned long    gs;
    unsigned short    es, ds, fsindex, gsindex;
    ...
};
```

通用寄存器的值保存在哪里?

eax, ebx等通用寄存器在上下文切换时保存在kernel mode stack (核心态下的栈中)

创建进程的系统调用

- 1. fork用于创建新进程
- 2. vfork创建新进程,并且只有当子进程运行完毕,父进程才能运行;二者共享存储空间(deprecated)
- 3. clone用于创建进程或者线程

创建进程的系统调用: 写拷贝技术(copy-on-write)

历史上, unix中调用fork创建新进程时, OS需要将父进程的存储空间完全拷贝一份给子进程, 这有以下缺点:

- ▶ 拷贝内存的过程非常耗时
- ▶ 需要占用大量内存空间
- ▶ 子进程一旦执行exec,则上述拷贝完全浪费

写拷贝(copy-on-write): 创建新进程时,仅拷贝父进程的页表,并将所有页表项对应的页面设置成只读,只有当父亲或子进程需要写入某页面时,才拷贝相应页面的内容。

创建进程: do_fork函数

kernel/fork.c

- ► clone_flags用于描述进程的哪些属性将被复制(进程/线程!)
- ▶ start_stack为用户态下进程的栈起始位置, stack_size为栈的 总长度
- ▶ regs, parent_tidptr等参数后面讲

创建进程: do_fork函数

arch/x86/kernel/process_32.c

创建进程: do_fork函数

arch/x86/kernel/process_32.c

```
asmlinkage int sys_clone(struct pt_regs regs)
    unsigned long clone flags;
    unsigned long newsp;
    int user *parent tidptr, *child tidptr;
    clone flags = regs.ebx;
    newsp = regs.ecx;
    parent_tidptr = (int __user *)regs.edx;
    child_tidptr = (int __user *)regs.edi;
    if (!newsp)
        newsp = regs.esp;
    return do_fork(clone_flags, newsp, &regs,
                   0, parent_tidptr, child_tidptr);
```