OS概念与Linux内核代码分析之三：进程同步

李中国

苏州大学计算机科学与技术学院

June 5, 2012

内容提要

原子操作

实现分段的硬件装置

Linux + Intel平台上的内存分页

内容提要

原子操作

实现分段的硬件装置

Linux + Intel平台上的内存分页

内容提要

原子操作

实现分段的硬件装置

Linux + Intel平台上的内存分页

什么是原子操作?

原子操作的定义

整个操作(计算机执行的指令序列)不可分割，要么全部做完，要么全部不做。

不能保证是原子操作的例子

```
a = a + 1;
a++;
```

这些C语言语句都涉及read-modify-write这样的机器指令序列，因而不是原子操作。

原子操作的例子

- 如果某指令不涉及内存地址，则肯定是原子操作
- Intel平台上，如果指令前面有lock标记(0xf0), 则是原子操作

Linux内核中的atomic_t类型及操作

include/asm-x86_64/atomic.h

```
typedef struct __atomic_t {
    volatile int counter;
} atomic_t;

#define ATOMIC_INIT(i)  { (i) }

#define atomic_read(v)  ((v)->counter)

static __inline__ void atomic_add(int i,
   atomic_t *v)
{
    __asm__ __volatile__(
        LOCK "addl %1,%0"
        :"=m" (v->counter)
        :"ir" (i), "m" (v->counter));
}
```

内存寻址: 实模式与保护模式

实模式 寻址采用和8086相同的16位段和偏移量，最大寻址空间1MB(4*seg + off)，最大分段64KB。

保护模式 寻址采用32位段和偏移量，最大寻址空间4GB，最大分段4GB (Pentium Pre及以后为64GB)。

两种模式的主要区别

二者的根本区别是进程内存受保护与否。实模式下系统程序和用户程序没有区别对待，每一个指针都是指向"实在"的物理地址。

段选择符及段寄存器

段选择符

逻辑地址由16位的段号(segment ID)和32位段内偏移(offset)组成. 其中段号在Intel平台上称为段选择符(segment selector). 其16个二进制位中存放信息如下图。

段寄存器

CPU内部专门用来存放段选择符的存储单元。共有六个： cs, ss, ds, es, fs, gs. 其中：

- cs 代码段寄存器(程序指令)
- ss 栈段寄存器(运行时的栈)
- ds 数据段寄存器(全局及静态变量)

段描述符

内存分段后，每个段表项存放相应段的性质（如地址、存放内容的类型等）. 段表项在Intel平台上称为段描述符(segment descriptor). 有两类段表: 全局段表(GDT,系统中仅有一个), 局部段表(LDT,每个进程可以单独有一个).

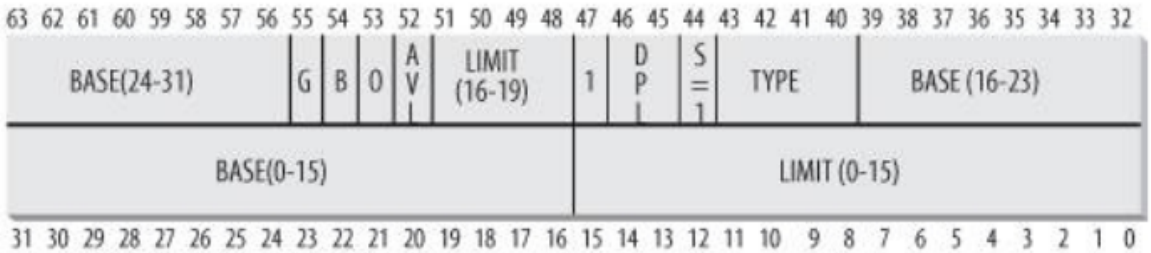

几个关键字段

Base 该段起始地址

Limit 该段总长度

G 标记Limit字段的单位是1字节还是4096字节

Type 该段类型(代码、数据、其它)

段选择符的三个字段

index 用于对段表进行索引

TI 用于指定该选择符对应GDT(TI=0)还是LDT(TI=1)

RPL 记录CPU权限状态(核心态/用户态)

从逻辑地址到线性地址的映射

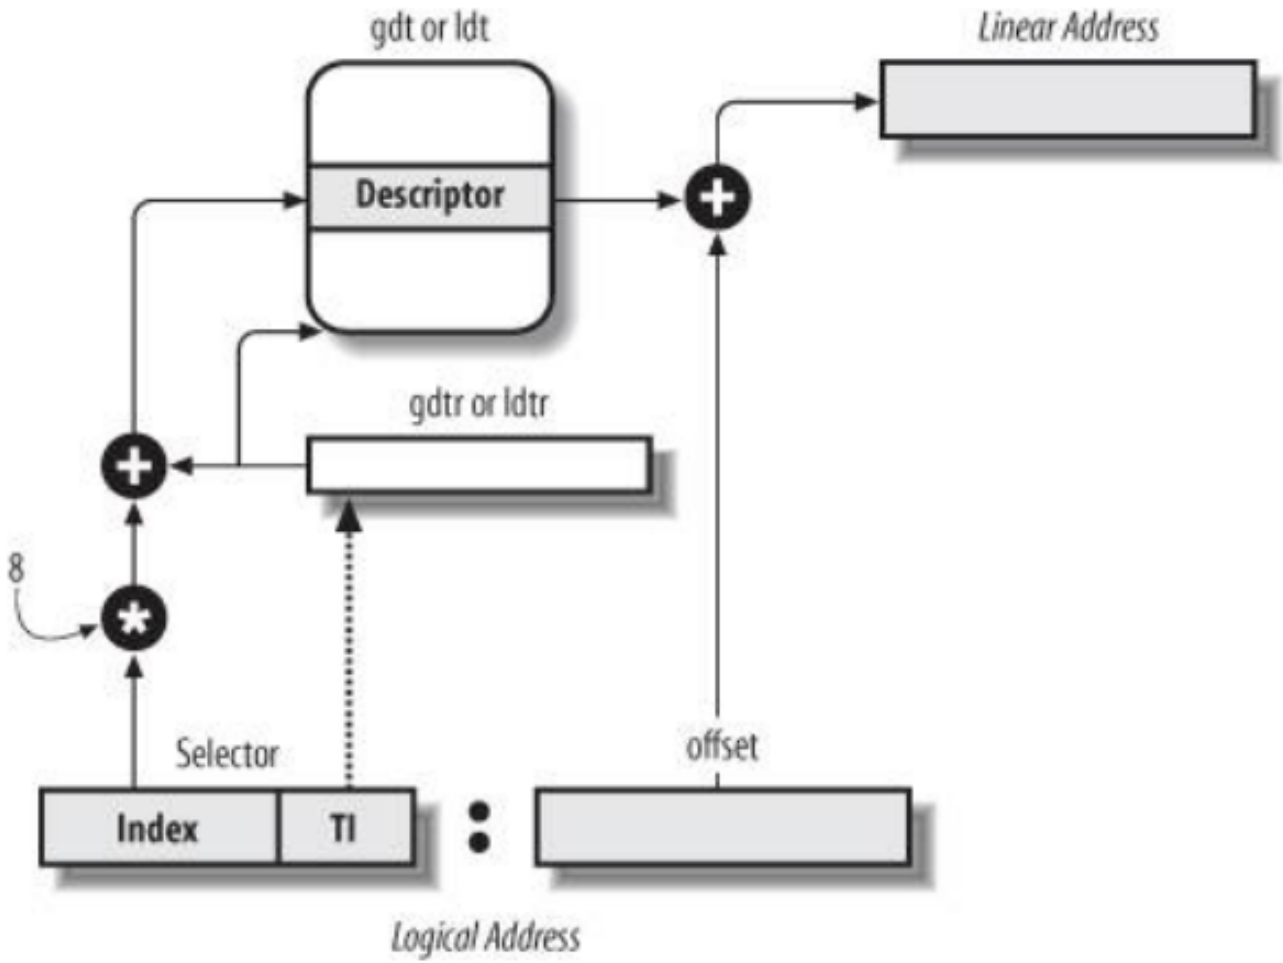

Intel平台上的分页技术

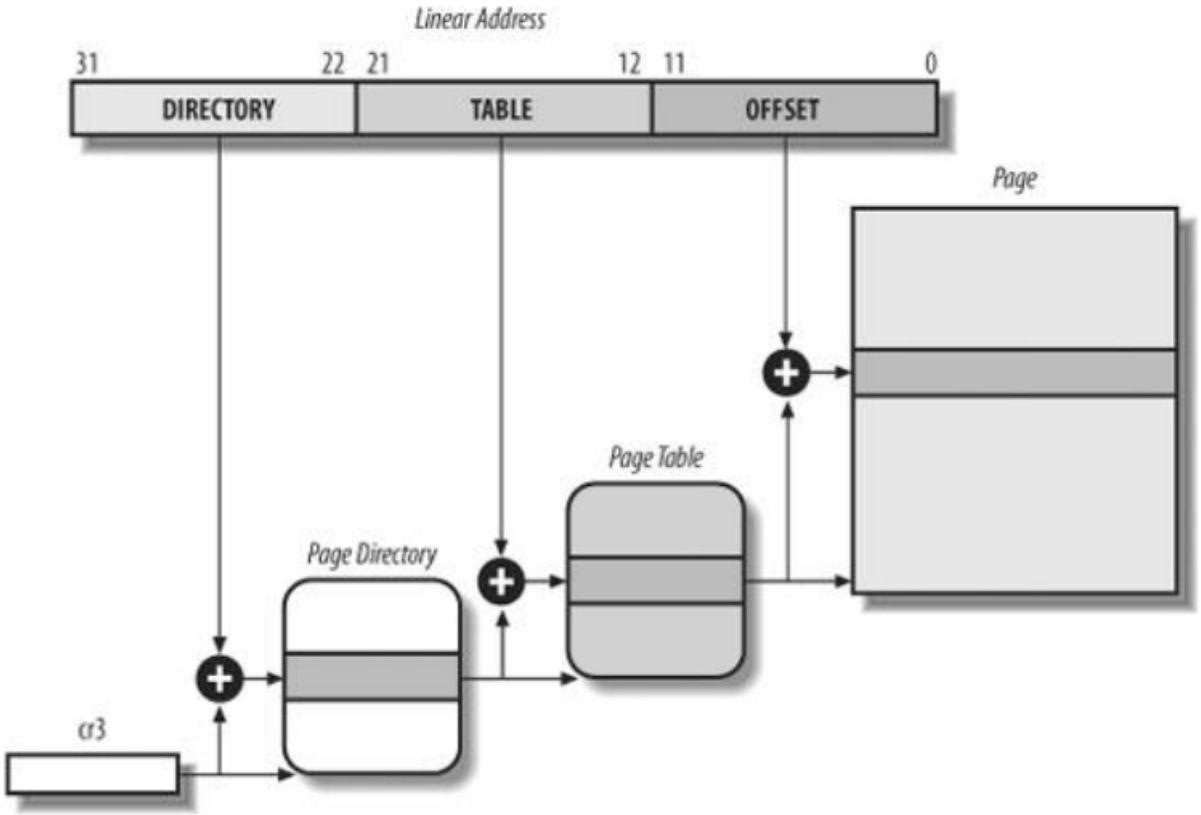

cr3寄存器用于存放当前进程的page directory(第一级页表).

Intel平台上的扩展分页模式

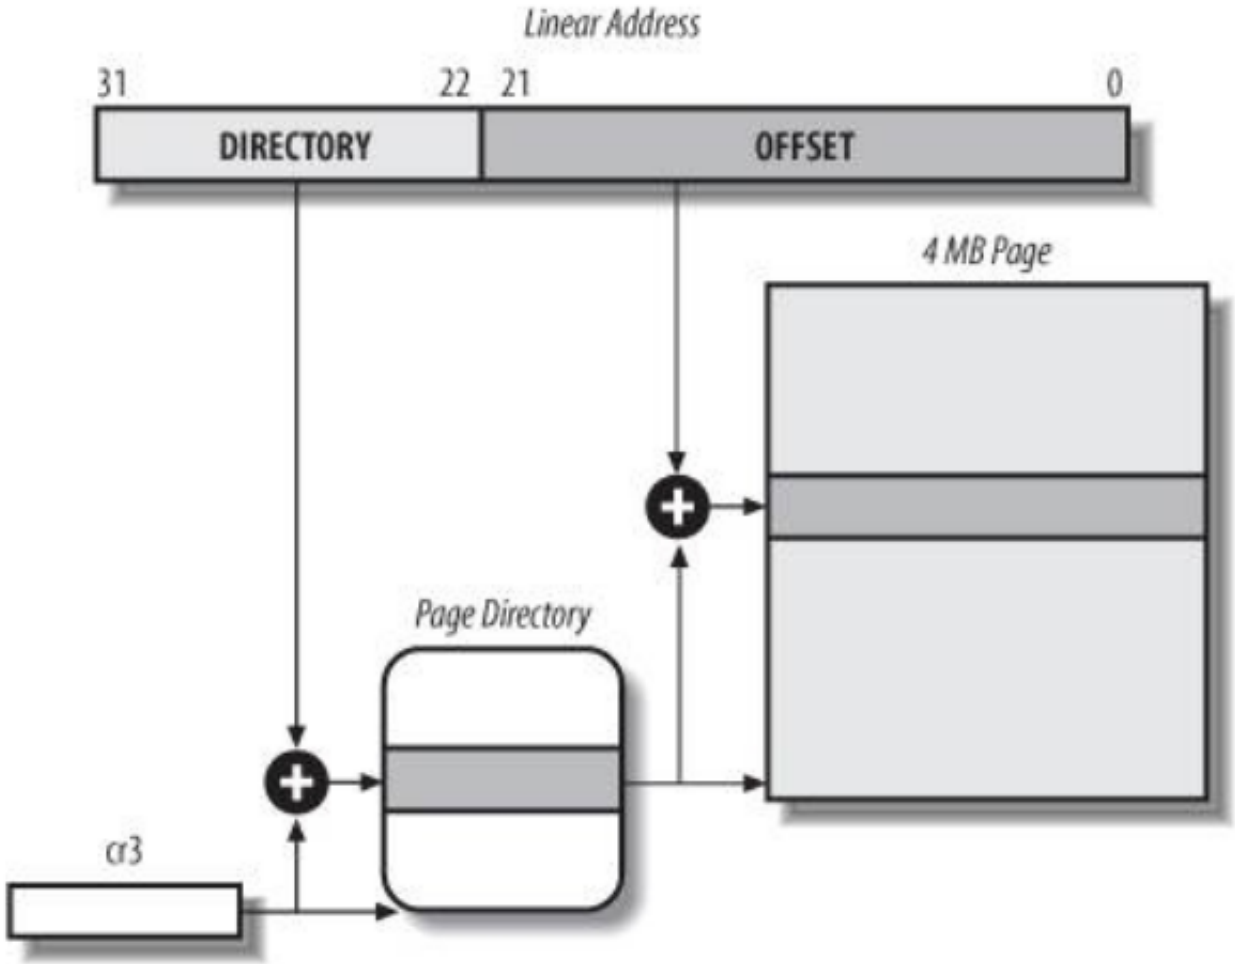

扩展分页模式下，页面大小为4M，用于处理大块连续地址空间，以节省页表所占空间及TLB空间。

分页的实际例子

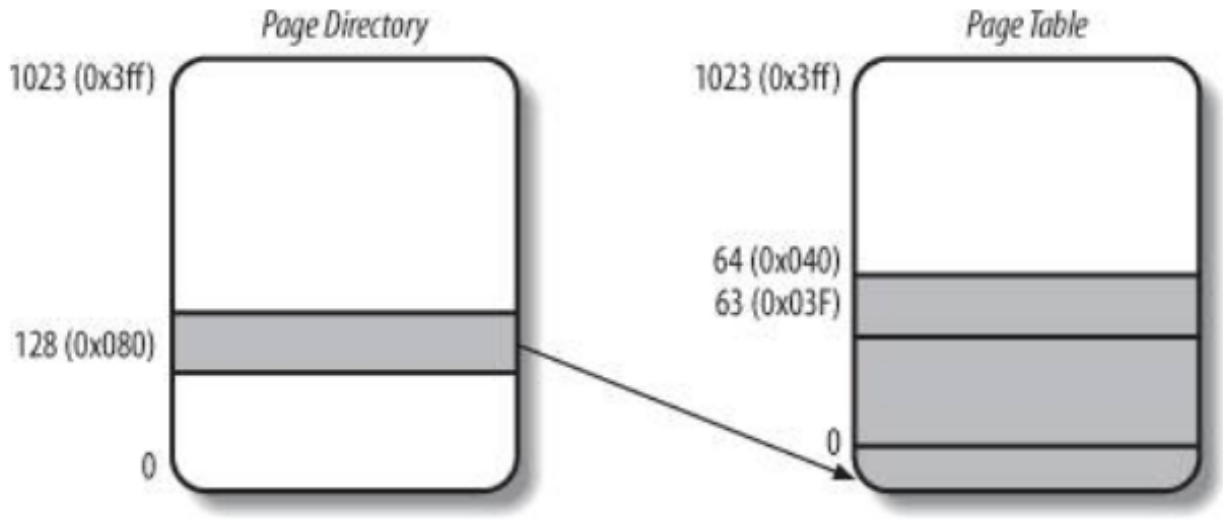

假设内核把从0x20000000到0x2003ffff之间的线性地址(共64页)分配给某进程。

- 该段地址最高10位均为0010000000, 即0x080(十进制128)，因此第一级页表只有一个页表项有效。
- 该段地址中间10位范围为0 – 0x03f(即0 – 63). 所以第二级页表中开头64个页表项有效。(图示灰色区域)
- 给定线性地址0x20021406，如何确定其对应的物理地址?

Linux的分页技术实现方式

为了能够同时处理32位和64位机器的分页方式, Linux创造性地使用4级分页来同时适应硬件1–4级分页需求。

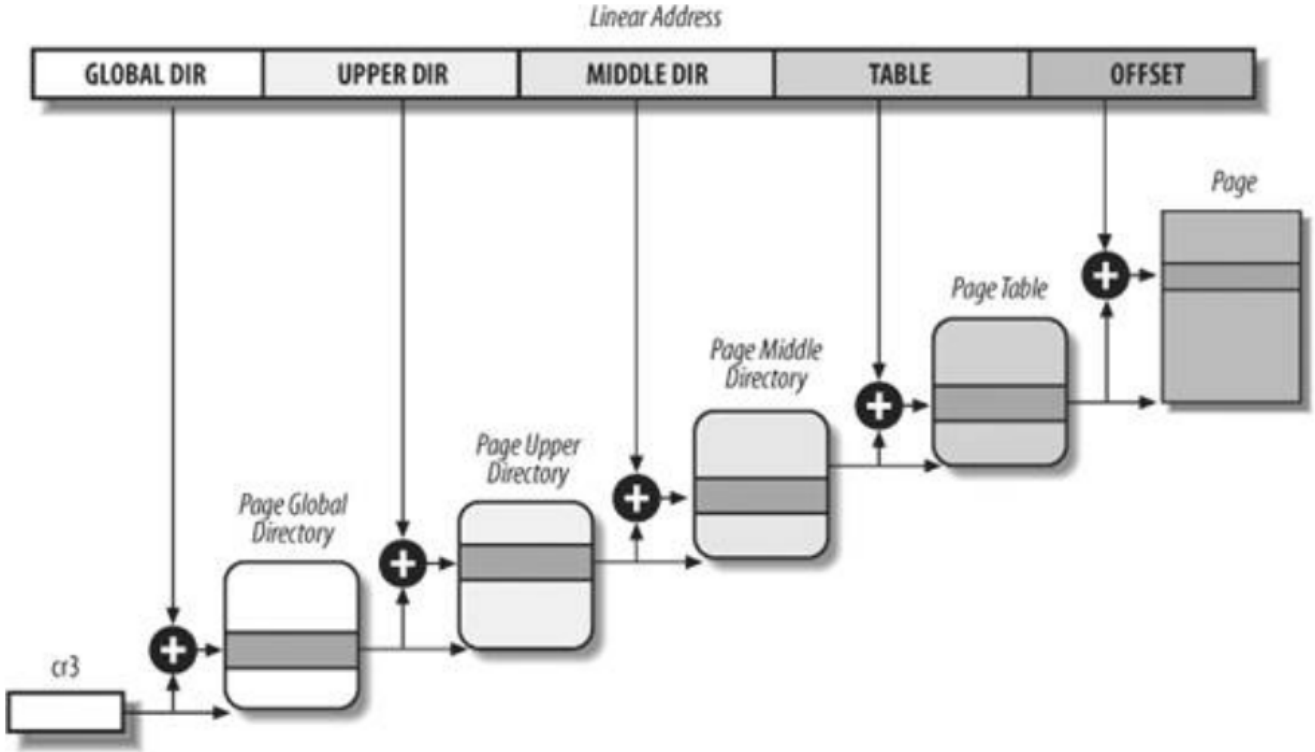

Linux的分页技术实现方式

上图中共有四种类型的页表:

Page Global Directory

Page Upper Directory

Page Middle Directory

Page Table

对于32位机器，2级页表就够了，此时，Linux把Page Upper Directory和Page Middle Directory两字段对应的地址长度设置为0.

有关线性地址各个字段及页表项的一些宏

include/asm-x86_64/{page.h, pgtable.h}

- PAGE_SHIFT, PAGE_SIZE, PAGE_MASK
- PMD_SHIFT, PMD_SIZE, PMD_MASK
- PUD_SHIFT, PUD_SIZE, PUD_MASK
- PGDIR_SHIFT, PGDIR_SIZE, PGDIR_MASK

如何根据SHIFT, SIZE, MASK的关系定义上述宏?

include/asm-x86_64/pgtable.h

- PTRS_PER_PTE
- PTRS_PER_PMD
- PTRS_PER_PUD
- PTRS_PER_PGD

需要注意32位和64位机器(页表级数不同)上述值的差别。

处理页表的函数

各类页表项的定义: include/asm-x86_64/page.h

```
typedef struct { unsigned long pte; } pte_t;
typedef struct { unsigned long pmd; } pmd_t;
typedef struct { unsigned long pud; } pud_t;
typedef struct { unsigned long pgd; } pgd_t;
```

注: Linux内核以后缀_t表示系统自定义类型。

思考

为什么不直接用unsigned long表示各类页表项?

处理页表的函数

include/asm-x86_64/page.h

```
#define pte_val(x)   ((x).pte)
#define pmd_val(x)   ((x).pmd)
#define pud_val(x)   ((x).pud)
#define pgd_val(x)   ((x).pgd)
#define pgprot_val(x)    ((x).pgprot)

#define __pte(x) ((pte_t) { (x) } )
#define __pmd(x) ((pmd_t) { (x) } )
#define __pud(x) ((pud_t) { (x) } )
#define __pgd(x) ((pgd_t) { (x) } )
#define __pgprot(x) ((pgprot_t) { (x) } )
```